

动态环境中的全局引导轨迹规划

Globally Guided Trajectory Planning in Dynamic Environments

Oscar de Groot · Laura Ferranti · Darius Gavrila · Javier Alonso-Mora

代尔夫特理工大学认知机器人系，荷兰代尔夫特，邮编 2628 CD。电子邮箱：o.m.degroot@tudelft.nl

中文全文译稿（非官方） | 依据用户提供的 arXiv:2303.07751v1 [cs.RO], 2023 年 3 月 14 日版本。正文保留原文的论断、编号与实验数值；公式沿用原符号，原图保留并配中文图注及必要的图内文字对照。参考文献保留原始检索信息并附题名中译。原文的疑似笔误和内部不一致之处集中列于文末“译注”，不在正文中静默改写。

摘要

使移动机器人在与人类共享的环境中导航具有挑战性。从机器人的角度看，人类是必须避开的动态障碍物。这些障碍物使无碰撞空间具有非凸性，每个障碍物因而对应两种不同的通过行为，即从左侧或右侧通过。对于滚动时域轨迹优化等局部规划器，每种行为都对应一个可能使规划器陷入其中的局部最优解。即使存在更好的规划方案，这也可能导致运动缓慢或不安全。本文通过考虑轨迹的拓扑，识别多种局部最优行驶行为所对应的轨迹。通过传播拓扑信息，我们使这种识别在连续迭代之间保持一致。最合适的高层轨迹用于引导一个基于局部优化的规划器，从而生成快速且安全的运动规划。我们通过移动机器人的仿真和真实环境实验验证了所提出的规划器。

1. 引言

移动机器人有潜力实现物流任务的自动化，其应用范围既包括自动化仓库和医院中的室内运输，也包括包裹配送等室外运输。移动机器人面临的主要挑战之一，是在人群中安全地运动。

通常会对机器人的运动施加动态避碰约束，这使其自由构型空间变为非凸。事实上，二维环境中的每个障碍物至少会产生两种可能的行驶行为：从左侧通过或从右侧通过。

现有运动规划器可分为局部规划器和全局规划器。局部规划器通常会停留在初始化时给定的行驶行为中。如果存在性能更好的行驶行为却未被探索，就可能导致性能不佳，例如较长的通行时间。由于考虑范围有限，这类规划器通常运行较快，并且能够考虑详细的动力学模型。全局规划器会探索并寻找最优的行驶行为和运动规划，但在考虑机器人动力学模型时，可能需要较长的计算时间。

对于存在静态障碍物的场景，一种常见做法是先用全局规划器找到高层路径，再把这条路径交给局部运动规划器，以局部改进规划质量。采用这种分层结构的大多数现有工作，并不在全局规划器中考虑动态障碍物，而是直接把动态避碰交由局部规划器处理。尽管这样在计算上更快，却未能处理以下事实：当障碍物移动时，可供选择的行驶行为更加丰富，因为规划器需要决定何时以及如何通过障碍物。图 1 将规划问题置于由二维位置和有界时间组成的三维状态空间中，展示了这些行驶行为。每种行驶行为都会经过状态空间中不同的区域，因此可以通过分析其在无碰撞空间中的拓扑来识别。




图 1 在两个行人同时横穿的场景中，拓扑不同的引导轨迹如何探索不同的行驶行为。(a) 横穿场景的俯视图。(b) 三维状态空间中拓扑不同的轨迹。图内文字：Start=起点，Goal=目标，Time=时间，Passing Left=从左侧通过，Passing Right=从右侧通过，Slowing Down=减速，Speeding Up=加速。

本文通过在状态空间中规划拓扑不同的引导轨迹，显式考虑动态环境中可能的行驶行为。我们依据高层代价选出最合适的引导轨迹，并将其传递给模型预测轮廓控制器（Model Predictive Contouring Controller, MPCC）[1]。该控制器在跟随选定引导轨迹的同时，对机器人的运动进行局部优化，从而生成快速且安全的运动规划。

相关工作

可以利用局部优化规划局部最优轨迹。模型预测控制（Model Predictive Control, MPC）常用于在满足约束（例如避碰、车辆模型和执行器限制）的同时，优化规划性能（例如速度和舒适性）。它提供了一个灵活且安全的框架，能够纳入道路跟随 [2]，以及确定性情形 [1] 和不确定性情形 [3]、[4]、[5] 下的动态避碰。MPC 运动规划器的一个局限是，它们的解只能保证局部最优。当局部最优解对应不合适的行驶行为，例如过于激进或过于缓慢时，便可能产生不安全或出乎预期的行为。

快速扩展随机树（RRT）[6]、RRT* [7] 和概率路线图（PRM）[8] 等全局规划器原则上能够解决这一问题，但其运行速度通常不足以处理动态障碍物，尤其是在考虑机器人动力学约束时。

基于拓扑的规划方法通过比较轨迹拓扑，识别穿越环境的不同运动行为。如果两条轨迹能够在不与障碍物碰撞的情况下平滑地相互变形，则它们是同伦等价的。文献 [9] 将使用这一度量的方法分为三类。第一类方法在给定的同伦类中进行规划。例如，文献 [10] 利用道路规则，为高速公路行驶确定一个期望的同伦类。

第二类方法利用环境结构枚举可能的同伦类，然后计算其中一部分同伦类内的轨迹。文献 [11] 是这类方法的一个例子，它使用梯形分解对二维工作空间进行分解。类似地，文献 [12]、[13] 从道路结构中推导同伦类。文献 [14]、[15] 计算一种同调不变量，该不变量针对每个障碍物识别路径绕其旋转的情况。将这一不变量扩展到图中，就可以在每一个同调类中规划一条路径。

原文脚注 1：同调与同伦略有不同。定义见文献 [14]。

第三类方法在找到轨迹后，再评估其同伦关系。文献 [16]、[17] 使用文献 [14] 中的同调不变量，在静态障碍物周围扩展 PRM 图，并由局部规划器优化得到的高层轨迹。作为同伦的一种替代，文献 [19] 在可见形变（VD）[18] 的基础上引入了 UVD 可见形变，能够高效地比较两条轨迹的拓扑。该工作提出了一种考虑 UVD 的可见性 PRM（参见 [20]），用于实时规划无人机飞行的多条不同轨迹。文献 [21]、[22] 也利用了同一方法，在静态环境中的无人机飞行任务上取得了当时先进的结果。

第二类中的已有工作 [10]、[12]、[13] 在状态空间中针对动态障碍物进行规划，但它们都假设并利用了道路结构。第三类中的工作 [19]、[21]、[22] 则在非结构化三维环境中规划无人机飞行，但不考虑动态障碍物。

本文贡献

本文基于文献 [19] 提出一种属于第三类的方法，用于在不依赖道路结构的情况下规划穿越动态环境的轨迹。本文的贡献如下：

- 1) 提出一种规划器，在不假设环境具有结构性的前提下，考虑动态环境中多条拓扑不同的高层轨迹，并选择最合适的轨迹，作为局部规划器的初始化结果，即引导。
- 2) 提出一种算法，用于识别轨迹的拓扑信息并将其传播到后续迭代，使规划器的行为保持稳定和一致。

我们在移动机器人上通过仿真和真实环境实验验证了所提出的规划器。结果表明，加入高层规划器能够得到通行更快的轨迹，而且场景越拥挤，这种改善越明显。此外，我们在拥挤场景中观察到更少的碰撞。规划器采用 ROS/C++ 实现，并将以开源形式发布。

作者与资助说明：作者均来自荷兰代尔夫特理工大学认知机器人系。本研究得到荷兰科学基金 NWO-TTW 的支持，涉及 SafeVRU 项目（编号 14667）以及 Veni 项目 HARMONIA（编号 18165）。

II. 问题建模

我们采用确定性的离散时间非线性动力学描述机器人的运动：

$$x_{k+1} = f(x_k, u_k), \quad (1)$$

其中， $x_k \in \mathbb{R}^{n_x}$ 和 $u_k \in \mathbb{R}^{n_u}$ 分别是离散时刻 k 的状态和输入， n_x 和 n_u 分别为状态维数和输入维数。状态包含机器人的二维位置 $p_k = (x_k, y_k) \in \mathbb{R}^2 \subseteq \mathbb{R}^{n_x}$ 。障碍物与机器人在同一空间中运动。障碍物 j 在时刻 $k=0$ 的位置记为 $o_0^j \in \mathbb{R}^2$ 。我们假设，机器人在每个时刻都可以获得每个障碍物未来 N 个时间步的运动预测，即 $o_1^j, \dots, o_N^j$ 。障碍物和机器人各自由一个圆盘表示，其半径分别为 r_{obs} 和 r 。此外，假设机器人获得了一条需要跟随的高层参考路径，例如通向目标的直线。机器人沿参考路径穿过工作空间，可以偏离该路径，但不能与障碍物发生碰撞。

III. 全局引导

所提出的规划器由两个组成部分构成：第一个部分计算全局引导轨迹，用来引导第二个部分，即局部规划器，获得动态环境中的全局最优解。我们将引导轨迹搜索设计得轻量而快速，使其给出全局最优解附近的一个估计。局部规划器以引导轨迹进行初始化，并利用更精确的机器人模型和约束，通过局部优化获得安全、高质量的轨迹。

A. 动态轨迹规划

通过在状态空间中规划高层无碰撞路径，我们显式考虑存在动态障碍物时多种局部最优的行驶行为。由工作空间和时间构成的状态空间记为 $\mathcal{X} = \mathbb{R}^2 \times [0, T]$ ，其中 $[0, T]$ 是连续区间。轨迹是穿过状态空间的一条连续路径， $\tau: [0, 1] \rightarrow \mathcal{X}$ 。时刻 t 所有障碍物的并集在工作空间中占据的区域记为 $\mathcal{O}_t \subset \mathbb{R}^2$ 。于是，状态空间中的障碍物集合为：

$$\mathcal{O} := \bigcup_{t \in [0, T]} (\mathcal{O}_t, t) \subset \mathcal{X}.$$

障碍物在状态空间中形成孔洞，使无碰撞空间变为非凸，并导致存在多个局部最优轨迹。

可以分析轨迹的拓扑，为每个局部最优解识别一条轨迹。为了区分轨迹拓扑，我们需要一个比较函数：

$$\mathcal{H}(\tau_i, \tau_j, \mathcal{O}) = \begin{cases} 1, & \tau_i, \tau_j \text{ 拓扑等价;} \\ 0, & \text{否则。} \end{cases} \quad (2)$$

随后，我们寻求工作空间中的拓扑不同轨迹集合 $\mathcal{T}^* = \{\tau_0, \tau_1, \dots, \tau_{N_\tau}\}$ ，满足：

$$\mathcal{H}(\tau_i, \tau_j, \mathcal{O}) = 0, \quad \forall \tau_i, \tau_j \in \mathcal{T}^*, \quad i \neq j. \quad (3)$$

本文采用 UVD [19] 作为拓扑度量。如果沿两条轨迹的点能够相互连接，且这些连接不与障碍物相交，则两条轨迹属于同一个 UVD 类，即拓扑等价。

定义 1 [19]： 设两条轨迹 $\tau_1(s)$ 、 $\tau_2(s)$ 以 $s \in [0, 1]$ 为参数，并满足 $\tau_1(0) = \tau_2(0)$ 、 $\tau_1(1) = \tau_2(1)$ 。如果对于所有 s ，线段 $\overline{\tau_1(s)\tau_2(s)}$ 都无碰撞，那么它们属于同一个一致可见形变类。

实际实现中，我们沿轨迹对参数 s 按离散间隔进行碰撞检查。




图 2 从状态空间 $\mathcal{X}$ 观察本文的高层引导方法。(a) 使用 Visibility-PRM 构建图；球体分别表示守卫（橙色）、起点和目标（红色），以及连接节点（其他颜色）。(b) 通过图搜索找到几何路径（彩色线），随后采样并平滑；立方体表示优化前（绿色）和优化后（黑色）的三次样条点。(c) 通过所得点拟合三次样条，并依据高层代价选择一条引导轨迹供局部规划器跟踪；选中的轨迹以加粗深蓝线表示。

B. 可见性 PRM (Visibility-PRM)

我们在 Visibility-PRM [19] 的基础上，计算从起点到目标的、具有不同拓扑的路径的稀疏表示。我们作出若干重要修改，使该方法能够用于包含时间的状态空间，并保证它在连续时间步之间给出一致的输出。修改后的 Visibility-PRM 如算法 1 所示，详细说明如下。

PRM 首先用起点节点 x_0 和目标节点 x_N 初始化图。新节点的状态从可行状态分布中随机抽取，即 $x^{(i)} \sim \mathcal{P}_{\text{PRM}}$ （第 8 行的 NewSample）。如果可以，就将新节点连接到图中。

为保证图的稀疏性，Visibility-PRM 区分守卫节点（Guard）和连接节点（Connector）。起点与目标节点被初始化为守卫（第 1、2 行）。对于每个新样本，我们寻找能够与之无碰撞连接的守卫（第 9 行的 VisibleGuards）。如果它能连接的守卫数为 0，就把它加入为守卫（第 11 行的 AddGuard）。当样本恰好能连接 2 个守卫时，它成为一个连接节点（第 17 行的 InitializeConnector）。对于连接节点，我们验证连接是否满足动力学可行性（第 13、15 行的 ConnectionInvalid）。随后在连接节点及两个守卫之间构造一条分段线性路径（Path）。当新采样的连接节点与已有连接节点属于同一个 UVD 类，且新路径更短时，第 22-29 行会替换已有连接节点。具有不同 UVD 类的新连接节点由第 32 行的 AddConnector 加入。

与文献 [16] 类似，我们采用带有已访问节点列表的深度优先图搜索，在图上计算从起点到目标的路径，从而得到 UVD 不同的轨迹集合 $\mathcal{T}^*$ 。我们将这些轨迹称为几何轨迹。图 2(a) 给出了结果示例。

算法 1 本文提出的 Visibility-PRM

输入: $\mathcal{O}$ 、 x_0 、 x_N 、上一轮节点集合 $\mathcal{G}^-$ 。输出: 图 $\mathcal{G}$ 。

```

1  AddGuard( $x_0, \mathcal{G}$ )
2  AddGuard( $x_N, \mathcal{G}$ )
3  当采样数和计算时间均未达到上限时, 循环:
4      reintroduce  $\leftarrow \mathcal{G}^-$  中仍有样本尚未重新引入
5      如果 reintroduce 为真:
6           $x, \mathcal{N}^- \leftarrow \text{ReintroduceSample}(\mathcal{G}^-)$ 
7      否则:
8           $x \leftarrow \text{NewSample}(x_0, x_N)$ 
9           $\mathcal{L} \leftarrow \text{VisibleGuards}(x, \mathcal{G}, \mathcal{O})$ 
10         如果  $|\mathcal{L}| = 0$  (没有可见守卫):
11             AddGuard( $x, \mathcal{G}$ )
12         否则, 如果  $|\mathcal{L}| = 2$  (恰有两个可见守卫):
13             如果 ConnectionInvalid( $\mathcal{L}_0, x$ ):
14                 继续下一次循环
15             如果 ConnectionInvalid( $x, \mathcal{L}_1$ ):
16                 继续下一次循环
17          $\mathcal{N} \leftarrow \text{InitializeConnector}(x)$ 
18         如果 reintroduce 为真:
19             将  $\mathcal{N}^-$  的片段 ID 转移给  $\mathcal{N}$ 
20          $\tau \leftarrow \text{Path}(\mathcal{L}_0, x, \mathcal{L}_1)$ 
21         distinct  $\leftarrow \text{True}$ 
22         遍历  $\mathcal{L}$  中守卫的每个共同邻居  $x^j, \mathcal{N}^j$ :
23              $\tau_j \leftarrow \text{Path}(\mathcal{L}_0, x^j, \mathcal{L}_1)$ 
24             如果  $\mathcal{H}(\tau, \tau_j, \mathcal{O}) = 1$ :
25                 distinct  $\leftarrow \text{False}$ 
26                 如果 Length( $\tau$ ) < Length( $\tau_j$ ):
27                     将  $\mathcal{N}^j$  的片段 ID 转移给  $\mathcal{N}$ 
28                     在  $\mathcal{G}$  中用  $\mathcal{N}$  替换连接节点  $\mathcal{N}^j$ 
29             退出当前 for 循环
30         如果 distinct 为真:
31             如果 reintroduce 为假:
32                 用一个尚未使用的 ID 初始化  $\mathcal{N}$  的片段 ID
33             AddConnector( $\mathcal{N}, \mathcal{G}$ )

```

C. 引导轨迹的跨周期传播

由于每个时间步都会重复搜索引导轨迹, 因此必须保证连续迭代之间的一致性, 以避免机器人在不同轨迹之间切换。我们通过为图中的节点标记拓扑标识符, 并在下一次迭代中连同这些标识符一起重新引入节点, 来处理这一问题。这样就能重新识别上一轮选中的引导轨迹, 并对它给予偏好。

按照图的构造方式，每个由一个连接节点和两个守卫组成的片段，都属于一个不同的 UVD 类。我们为每个连接节点 i 分配一个片段 ID， $\alpha_i \in \mathbb{Z}^+$ ，以唯一标识该片段（第 31 行）。连接节点被替换时，其 ID 会随之转移（第 27 行）。图 3 展示了这一过程。




图 3 每个片段都关联一个拓扑 ID。(a) 为两个具有新且不同拓扑的片段分配唯一 ID。(b) 新连接节点在已有拓扑内形成更短的片段，原 ID 转移给新连接节点。图内文字：Guard=守卫节点，Obstacle=障碍物；(a) 为新拓扑片段，(b) 为已有拓扑片段。

每条几何轨迹由一个或多个片段组成。我们为每条几何轨迹 i 关联一个轨迹 ID， $\beta_i \in \mathbb{Z}^+$ ，并维护轨迹与组成片段之间的映射，从而能够在连续迭代中重新识别每条轨迹。例如，若 ID 为 $\beta_i = 1$ 的轨迹 τ_1 包含片段 $\alpha_1 = 1$ 、 $\alpha_2 = 4$ ，我们首先保存映射 $1 \rightarrow \{1, 4\}$ 。在下一次迭代中，由片段 1 和 4 组成的轨迹会重新获得 ID 1。

在算法 1 第 6 行，ReintroduceSample 会先重新引入上一轮图 $\mathcal{G}^-$ 的所有节点，然后再采样新状态。两次迭代之间经过了一个采样周期，因此上一轮图中每个节点的时间坐标都需要由 (x, y, t) 更新为 $(x, y, t - h)$ ，其中 h 为采样周期。当时间坐标变为零时，我们沿轨迹中途的位置重新采样一个新节点。

由于连接节点带有片段 ID，上一轮迭代中的片段关联能够被保留下来（第 19 行）。找到新路径后，我们根据其片段重新识别之前的轨迹。上述步骤使 UVD 不同轨迹的识别保持一致；同时，由于轨迹及其拓扑被传播到后续迭代，规划器的整体性能也得到改善。

D. 样条优化

几何轨迹不满足机器人的运动学约束，因为它们存在不连续性，因此低层控制器无法跟随。我们采用两个步骤对这些轨迹进行平滑，如图 2(b)、2(c) 所示。第一步对轨迹进行采样，并优化所得点；第二步通过优化后的点拟合平滑曲线。

步骤 1：首先，将状态空间路径转换为以时间为参数的轨迹 $\tau_{\text{geometric}} : [0, T] \rightarrow \mathbb{R}^2$ 。对每条轨迹以固定间隔 Δt 进行采样，得到控制点集合 $Q = [Q_0, \dots, Q_N]$ ，其中 $Q_i \in \mathbb{R}^2$ 。

我们优化这些控制点，以提高位置和速度的平滑性。为尽量减少计算时间，优化问题被设计为无约束二次问题。代价定义为：

$$J_{\text{points}} = J_{\text{geo}} + J_{\text{smooth}} + J_{\text{obst}} + J_{\text{vel}}, \quad (4)$$

其中，几何代价 [19] 惩罚控制点相对于几何轨迹上原始控制点 $\bar{Q}$ 的距离：

$$J_{\text{geo}} = \sum_i^N \|Q_i - \bar{Q}_i\|^2. \quad (5)$$

平滑代价 [19] 为：

$$J_{\text{smooth}} = \sum_{i=1}^{N-1} \|Q_{i-1} - 2Q_i + Q_{i+1}\|^2, \quad (6)$$

它像一条弹性带，使轨迹变得平滑。

障碍物代价通过指数惩罚，作用于控制点 i 到障碍物 j 的线性距离 d_i^j 。不过，为保持代价为二次形式，我们采用二阶泰勒展开。令 $A_{i,j} = \bar{Q}_i - o_k^j$ ，其中时间索引 k 与控制点 Q_i 所对应的时间相匹配。代价为：

$$J_{\text{obst}} = \sum_i \sum_j (Q_i^\top H_{i,j} Q_i + f_{i,j}^\top Q_i),$$

其中：

$$H_{i,j} = \frac{A_{i,j} A_{i,j}^\top}{2}, \quad f_{i,j} = -(1 + r + r_{\text{obs}}) A_{i,j} - 2H_{i,j} o_k^j.$$

速度代价惩罚相对于跟踪速度 v_{ref} 的偏差。为计算这一代价，我们根据几何轨迹构造一条在处处满足速度跟踪要求的轨迹，然后惩罚控制点到该轨迹的距离。几何路径的速度控制点可按下式计算：

$$V_i = \frac{Q_{i+1} - Q_i}{\Delta t}, \quad i = 1, \dots, N-1. \quad (7)$$

相应的速度优化路径为：

$$Q_{i+1}^v = Q_i^v + v_{\text{ref}} \frac{V_i}{\|V_i\|} \Delta t, \quad (8)$$

其中 Q_0^v 等于机器人的当前速度。速度代价与式 (5) 相同，只需将其中的 $\bar{Q}$ 替换为 Q^v 。

步骤 2：由于优化问题为无约束二次问题，我们可以获得闭式解。分别通过控制点优化后的 x 、 y 位置拟合三次样条，得到连续轨迹。该轨迹由若干段 $\tau^i(t) = [\tau_x^i \ \tau_y^i]^\top$ 组成，其中 τ_x^i (τ_y^i 同理) 为：

$$\tau_x^i(t) = a_x^i t^3 + b_x^i t^2 + c_x^i t + d_x,$$

该曲线二阶连续可微，并通过控制点。我们对轨迹的初始速度施加边界条件，使其与机器人当前速度一致。关于三次样条拟合的更多细节，参见文献 [23]。这些三次样条共同组成一条从机器人当前位置通向目标的平滑轨迹 $\tau: [0, T] \rightarrow \mathbb{R}^2$ ，见图 2(c)。引导轨迹 τ 并不保证无碰撞，但它足够平滑，可以供施加避碰约束的局部规划器使用。

E. 样条选择

对于每个控制周期生成的候选样条，我们需要选择最能体现机器人运动性能指标的引导轨迹。我们考虑以下准则：

- 1) 最小化路径长度：偏好较短的路径。
- 2) 最小化与期望速度之间的差异：惩罚过快或过慢的行驶。
- 3) 最小化加速度：偏好平滑的轨迹。
- 4) 一致性：当另一条轨迹优于上一控制周期选中的轨迹时，要求它具有显著优势。

我们沿每条轨迹以固定时间间隔采样位置 p_i 、速度 v_i 和加速度 a_i ，据此计算轨迹代价，得到目标函数：

$$J_{\text{select}} = \sum_{i \in \mathcal{I}} [w_L \|p_i - p_{i-1}\| + w_V |\|v_i\| - \bar{v}| + w_a \alpha^i \|a_i\|] + w_c C, \quad (9)$$

其中， $\mathcal{I}$ 表示采样点数， w 表示权重， $\bar{v}$ 为参考速度， $\alpha \approx 1$ 用于折扣轨迹较后部分的加速度；如果该轨迹不是上一轮迭代选中的轨迹，则 C 表示一个常数惩罚。我们选择代价最低的轨迹，如图 2(c) 中的加粗轨迹所示。

IV. 局部规划

由于引导轨迹不能保证可行性，局部规划器需要规划运动学可行且无碰撞的运动。我们通过两种方式把引导轨迹引入局部规划器。首先，使用引导轨迹初始化求解器。但仅凭这一点，可能不足以收敛到期望的最优解。因此，我们还采用 MPCC [1] 作为局部规划器，使其跟随引导轨迹。该规划器被设计为跟随引导轨迹所描绘的路径，同时跟踪其速度。

MPCC 的目标函数为：

$$J_{\text{local}} = \sum_{k=0}^{N_{\text{MPCC}}} (J_{c,k} + J_{l,k} + J_{v,k} + J_{a,k} + J_{\omega,k}), \quad (10)$$

其中， $J_{c,k}$ 和 $J_{l,k}$ 表示文献 [1] 中的滞后代价与轮廓代价。速度参考跟踪通过 $J_{v,k} = \|v_k - \bar{v}_k\|$ 实现，其中 $\bar{v}_k$ 是引导轨迹在时间步 k 的速度。代价 $J_{a,k}$ 和 $J_{\omega,k}$ 用于惩罚控制作用。

为避开障碍物，通常使用非凸约束 $\|p_k - o_k\| \geq r + r_{\text{obs}}$ [1]。然而在实践中，这可能导致局部最优解之间的切换，无法给出一致的解。我们采用这些约束的线性化版本，即与机器人和障碍物之间向量正交的线性约束 $A^\top p_k \leq b$ ，其中：

$$A = \frac{o_k - p_k}{\|o_k - p_k\|}, \quad b = A^\top (o_k - A(r + r_{\text{obs}})). \quad (11)$$

这些约束能够产生一致且平滑的运动。

原文脚注 2：原则上，我们可以为每条引导轨迹并行运行一个局部规划器，再选择其中最好的结果。这将留待未来研究。

V. 实验结果

我们通过仿真和真实环境实验验证所提出的方法，两种情况下均与不使用引导的局部规划器进行比较。规划器采用 ROS/C++ 实现，并将以开源形式发布。仿真和实验视频见文献 [24]。

A. 实现说明

实验设置见表 I。高层规划器的速度足以在保持实时性的同时，采用比局部规划器更长的规划时域，即 $N_{\text{PRM}} > N_{\text{MPCC}}$ 。在拥挤场景中，这会产生更平滑的轨迹，因为机器人可以更早调整高层机动行为。我们将 PRM 的目标选为沿参考路径以期望速度行驶时所能到达的位置。必要时，将该位置投影到最近的无碰撞位置。如果目标无法到达，我们就缩短规划时域。PRM 节点从一个考虑速度和加速度限制的前向弧形区域中采样，即采样分布 $\mathcal{P}_{\text{PRM}}$ 。

表 I 实验设置。“(w)” 表示权重。

分组	参数 / 权重	数值
整体	$N_{\text{PRM}}; N_{\text{MPCC}}; h; \bar{v}$	120; 40; 0.05 s; 2 m/s
控制点 (w)	$J_{\text{geo}}; J_{\text{smooth}}; J_{\text{obst}}; J_{\text{vel}}$	25; 10; 0.5; 0.01
样条	控制点数; $w_L; w_V; w_a; w_c; \alpha$	20; 1; 100; 100; 25; 0.95
MPCC (w)	$J_{c,k}^{\text{MPCC}}; J_{c,k}^{\text{Guidance}}$	0.01; 0.5
MPCC (w)	$J_{l,k}; J_{v,k}; J_{a,k}; J_{\omega,k}$	0.01; 0.3; 0.05; 0.05

B. 仿真中的引导消融研究

仿真考虑四种含有行人的环境。第一种为迎面相遇场景：在一条笔直道路上，两名行人朝机器人走来。其余环境分别包含 4、8、16 名行人，他们在参考路径附近具有随机的初始位置和速度。所有规划器使用相同的随机场景，即相同随机种子。在全部仿真中，行人均以恒定速度运动。当机器人沿 x 方向到达道路终点时，我们重置仿真，并对每项实验重复 200 次。





图 4 从状态空间观察的仿真快照。(a) 2 人迎面相遇；(b) 随机 4 人；(c) 随机 8 人；(d) 随机 16 人。黑色圆盘表示行人，彩色圆盘表示按机器人占据区域膨胀后的行人预测区域。图结构和引导轨迹的可视化与图 2 相同。蓝色圆盘表示机器人的局部运动规划，即预测的机器人占据区域。


统计结果见表 II，场景快照见图 4。在迎面相遇场景中，引导使机器人能够一致地绕开行人。如果没有引导，规划器的犹豫不决会在大多数仿真中导致不可行性和碰撞。在随机环境中，引导使任务完成时间分别缩短 2%、3% 和 5%，而且环境越拥挤，改善越明显。图 5 所示的 8 人场景轨迹表明，引导使规划器能够选择更快的行驶行为。

表 II 在四种不同场景中，分别进行 200 次仿真，比较使用与不使用引导的 MPCC 的任务完成时间、碰撞数及计算时间。除碰撞数外，结果均表示为实验中的“均值（标准差）”。“高层规划时间”表示计算引导轨迹所用的时间。

场景	方法	任务时间 [s]	碰撞数	计算时间 [ms]	高层规划时间 [ms]
迎面 2 人	LMPCC	13.3 (0.3)	160	17.1 (8.9)	-
	引导 MPCC	12.3 (0.1)	0	16.5 (2.9)	6.5 (2.1)
随机 4 人	LMPCC	12.3 (0.3)	0	17.2 (3.0)	-
	引导 MPCC	12.2 (0.2)	1	16.2 (2.6)	6.0 (1.9)
随机 8 人	LMPCC	12.7 (0.6)	3	17.2 (3.1)	-
	引导 MPCC	12.4 (0.4)	3	17.6 (3.7)	6.5 (2.3)
随机 16 人	LMPCC	13.5 (1.1)	16	19.4 (4.3)	-
	引导 MPCC	13.2 (1.0)	17	22.1 (6.7)	8.5 (4.6)



(a) Guidance-MPCC



(b) MPCC

图 5 在含 8 名行人的随机环境中，比较使用与不使用引导时的轨迹。(a) Guidance-MPCC：带引导的 MPCC；(b) MPCC：不使用引导的 MPCC。横纵坐标分别为 x 、 y ，单位为米。

带引导的 MPCC 发生碰撞的次数略多于基线。当障碍物阻挡路径时，高层规划器可能找不到引导轨迹。此时，我们使用上一次计算得到的引导轨迹，这可能导致碰撞。未来工作可以通过考虑多个目标来解决这一问题。

C. 真实环境实验

我们将所提出的规划器部署到移动机器人 Clearpath Jackal 上，在行人中导航。机器人配备一颗主频为 2.6 GHz 的 Intel i5 CPU。机器人与行人的定位来自基于标记的跟踪系统。行人预测采用恒速假设，速度由经过卡尔曼滤波的位置数据获得。




图 6 真实环境实验中记录的机器人轨迹（深蓝色）与行人轨迹（绿色）；起始位置以黑色标记。(a) 实验装置；(b) 横穿场景；(c) 混合场景。

图 6 展示了两个场景中的轨迹及实验装置。在第一个场景中，引导使机器人能够从最后一名行人的后方通过。在第二个场景中，机器人向左移动，高效地避开两名行人。

VI. 结论

本文提出了一种用于动态环境自主导航的新规划器。该规划器找到不同的高层轨迹，用于引导基于局部优化的规划器获得全局最优规划。引导轨迹在连续控制迭代中被计算和跟踪。

我们表明，与单独使用局部规划器相比，所提出的规划器能够缩短平均任务完成时间，而且在更拥挤的环境中改善更明显。真实环境实验进一步验证了所提出的方法。

未来研究可以探索将引导轨迹搜索应用于人类运动预测，或使局部规划器产生符合社会规范的运动行为。

参考文献

- [1] B. Brito, B. Floor, L. Ferranti, and J. Alonso-Mora, "Model Predictive Contouring Control for Collision Avoidance in Unstructured Dynamic Environments," *IEEE Robot. Autom. Lett.*, vol. 4, no. 4, pp. 4459-4466, Oct. 2019.
题名中译：用于非结构化动态环境避碰的模型预测轮廓控制。
- [2] W. Schwarting, J. Alonso-Mora, L. Paull, S. Karaman, and D. Rus, "Safe Nonlinear Trajectory Generation for Parallel Autonomy With a Dynamic Vehicle Model," *IEEE Trans. Intelligent Transportation Systems*, vol. 19, no. 9, pp. 2994-3008, Sep. 2018.
题名中译：采用车辆动力学模型、用于并行自主系统的安全非线性轨迹生成。
- [3] H. Zhu and J. Alonso-Mora, "Chance-Constrained Collision Avoidance for MAVs in Dynamic Environments," *IEEE Robot. Autom. Lett.*, vol. 4, no. 2, pp. 776-783, Apr. 2019.
题名中译：动态环境中微型飞行器的机会约束避碰。
- [4] A. Wang, X. Huang, A. Jasour, and B. Williams, "Fast Risk Assessment for Autonomous Vehicles Using Learned Models of Agent Futures," *arXiv:2005.13458 [cs, stat]*, Jun. 2020.
题名中译：利用学习得到的交通参与者未来行为模型，对自动驾驶车辆进行快速风险评估。
- [5] O. de Groot, B. Brito, L. Ferranti, D. Gavrila, and J. Alonso-Mora, "Scenario-Based Trajectory Optimization in Uncertain Dynamic Environments," *IEEE Robot. Autom. Lett.*, pp. 5389-5396, 2021.
题名中译：不确定动态环境中基于场景的轨迹优化。
- [6] S. LaValle, "Rapidly-Exploring Random Trees: A New Tool for Path Planning," Computer Science Department, Iowa State University, Tech. Rep. TR 98-11, 1998. [Online]. Available: <http://janowiec.cs.iastate.edu/papers/rrt.ps>
题名中译：快速探索随机树：一种新的路径规划工具。
- [7] S. Karaman and E. Frazzoli, "Sampling-based algorithms for optimal motion planning," *The International Journal of Robotics Research*, vol. 30, no. 7, pp. 846-894, Jun. 2011. [Online]. Available: <http://journals.sagepub.com/doi/10.1177/0278364911406761>
题名中译：用于最优运动规划的采样算法。
- [8] L. Kavraki, P. Švestka, J.-C. Latombe, and M. Overmars, "Probabilistic roadmaps for path planning in high-dimensional configuration spaces," *IEEE Transactions on Robotics and Automation*, vol. 12, no. 4, pp. 566-580, Aug. 1996.
题名中译：用于高维构型空间路径规划的概率路线图。
- [9] E. H. Bes, "Path Planning with Homotopic Constraints for Autonomous Underwater Vehicles," Ph.D. dissertation, 2012.
题名中译：具有同伦约束的自主水下航行器路径规划。
- [10] P. Bender, O. Ç. Taş, J. Ziegler, and C. Stiller, "The combinatorial aspect of motion planning: Maneuver variants in structured environments," in *2015 IEEE Intelligent Vehicles Symposium (IV)*, Jun. 2015, pp. 1386-1392, ISSN: 1931-0587.
题名中译：运动规划的组合特性：结构化环境中的机动方案变体。
- [11] J. Park, S. Karumanchi, and K. Iagnemma, "Homotopy-Based Divide-and-Conquer Strategy for Optimal Trajectory Planning via Mixed-Integer Programming," *IEEE Transactions on Robotics*, vol. 31, no. 5, pp. 1101-1115, Oct. 2015.
题名中译：通过混合整数规划进行最优轨迹规划的基于同伦的分治策略。
- [12] B. Yi, P. Bender, F. Bonarens, and C. Stiller, "Model Predictive Trajectory Planning for Automated Driving," *IEEE Transactions on Intelligent Vehicles*, vol. 4, no. 1, pp. 24-38, Mar. 2019.
题名中译：用于自动驾驶的模型预测轨迹规划。
- [13] F. Althé and A. de La Fortelle, "Partitioning of the free space-time for on-road navigation of autonomous ground vehicles," in *2017 IEEE 56th Annual Conference on Decision and Control (CDC)*, Dec. 2017, pp. 2126-2133.
题名中译：用于自主地面车辆道路导航的自由时空划分。
- [14] S. Bhattacharya, R. Ghrist, and V. Kumar, "Persistent Homology for Path Planning in Uncertain Environments," *IEEE Transactions on Robotics*, vol. 31, no. 3, pp. 578-590, Jun. 2015.
题名中译：用于不确定环境路径规划的持续同调。

- [15] S. Bhattacharya, V. Kumar, and M. Likhachev, "Search-based Path Planning with Homotopy Class Constraints," Jul. 2010.
题名中译: 具有同伦类约束的基于搜索的路径规划。
- [16] C. Rösmann, F. Hoffmann, and T. Bertram, "Integrated online trajectory planning and optimization in distinctive topologies," *Robotics and Autonomous Systems*, vol. 88, pp. 142-153, Feb. 2017. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S0921889016300495>
题名中译: 不同拓扑中的在线轨迹规划与优化一体化方法。
- [17] C. Rösmann, A. Makarow, and T. Bertram, "Online Motion Planning based on Nonlinear Model Predictive Control with Non-Euclidean Rotation Groups," in *2021 European Control Conference (ECC)*, Jun. 2021, pp. 1583-1590. [Online]. Available: <http://arxiv.org/abs/2006.03534>
题名中译: 基于含非欧几里得旋转群的非线性模型预测控制的在线运动规划。
- [18] L. Jaillet and T. Simeon, "Path Deformation Roadmaps: Compact Graphs with Useful Cycles for Motion Planning," *The International Journal of Robotics Research*, vol. 27, no. 11-12, pp. 1175-1188, Nov. 2008. [Online]. Available: <https://doi.org/10.1177/0278364908098411>
题名中译: 路径形变路线图: 包含有用环路的紧凑运动规划图。
- [19] B. Zhou, F. Gao, J. Pan, and S. Shen, "Robust Real-time UAV Replanning Using Guided Gradient-based Optimization and Topological Paths," in *2020 IEEE International Conference on Robotics and Automation (ICRA)*, May 2020, pp. 1208-1214, ISSN: 2577-087X.
题名中译: 利用引导式梯度优化与拓扑路径实现鲁棒实时无人机重规划。
- [20] T. Siméon, J.-P. Laumond, and C. Nissoux, "Visibility-based probabilistic roadmaps for motion planning," *Advanced Robotics*, vol. 14, no. 6, pp. 477-493, Jan. 2000. [Online]. Available: <https://www.tandfonline.com/doi/full/10.1163/156855300741960>
题名中译: 用于运动规划的基于可见性的概率路线图。
- [21] R. Penicka, Y. Song, E. Kaufmann, and D. Scaramuzza, "Learning Minimum-Time Flight in Cluttered Environments," *IEEE Robotics and Automation Letters*, vol. 7, no. 3, pp. 7209-7216, Jul. 2022. [Online]. Available: <http://arxiv.org/abs/2203.15052>
题名中译: 学习在杂乱环境中的最短时间飞行。
- [22] R. Penicka and D. Scaramuzza, "Minimum-Time Quadrotor Waypoint Flight in Cluttered Environments," *arXiv, Tech. Rep.* arXiv:2202.03947, Feb. 2022. [Online]. Available: <http://arxiv.org/abs/2202.03947>
题名中译: 杂乱环境中四旋翼无人机经航路点的最短时间飞行。
- [23] T. Kluge, "Cubic Splines," Mar. 2021. [Online]. Available: <https://kluge.in-chemnitz.de/opensource/spline/spline.pdf>
题名中译: 三次样条。
- [24] O. de Groot, L. Ferranti, D. Gavrilu, and J. Alonso-Mora, "Globally Guided Trajectory Planning in Dynamic Environments," 2023. [Online]. Available: <https://www.youtube.com/watch?v=tkRbsAuSTrA>
题名中译: 动态环境中的全局引导轨迹规划 (配套视频)。

译注

以下说明属于译者核对记录，不属于论文原文；正文中的相关表述和数值均予保留。

1. UVD 的名称：原文引言将缩写展开为 Universal Visibility Deformation，而定义 1 使用 uniform visibility deformation。本文在一般叙述中写作“UVD 可见形变”，在定义处按原文译为“一致可见形变”。
2. 式 (8) 的初值：原文明确写道 Q_0^v 等于机器人的当前速度。但按该递推式， Q_i^v 表示位置，初值与速度的量纲不一致，疑为笔误。复现时应结合实现核对，不能直接将速度向量作为位置初值。正文保留原文说法。
3. 算法行号：原文 B 节把 AddConnector 引用为第 32 行，实际算法表中位于第 33 行；C 节把片段 ID 初始化引用为第 31 行，实际初始化操作位于第 32 行。正文保留原引用，算法完整保留 1-33 的原始行号。
4. 实验百分比与碰撞结论：原文在随机 4、8、16 人场景中声称任务时间分别降低 2%、3%、5%，但根据表 II 显示的均值计算，约为 0.8%、2.4%、2.2%。引言称拥挤场景碰撞更少，而表 II 中随机场景的碰撞数分别为 0→1、3→3、16→17；迎面相遇场景则为 160→0。译文保留了两处原始说法，阅读结论时应同时核对表格。
5. 若干符号说明：原文在式 (9) 中把 $\mathcal{I}$ 作为求和索引集合使用，但文字称其为采样点“数量”；第 IV 节按 $J_{c,k}$ 、 $J_{l,k}$ 的顺序写出“滞后与轮廓代价”，与常见 $c=\text{contour}$ 、 $l=\text{lag}$ 的下标习惯不一致。式 (11) 使用同一个 p_k 符号构造法向量并表示约束中的位置变量；实际线性化实现需区分固定的参考位置与待优化位置。
6. 表述范围：原文多处使用“全局最优”措辞，但本文未给出整个分层算法保证全局最优的定理。引导轨迹经过平滑后不保证无碰撞，这一点已由原文明确说明。原文“将开源”等时态按 2023 年版本保留，不代表当前代码发布状态。